

Deep_L_Act_1

October 5, 2023

Estefanía Pérez Yeo - A01639270

1 Cifar10

```
[103]: import tensorflow as tf
from tensorflow.keras import datasets, layers, models
import matplotlib.pyplot as plt
```

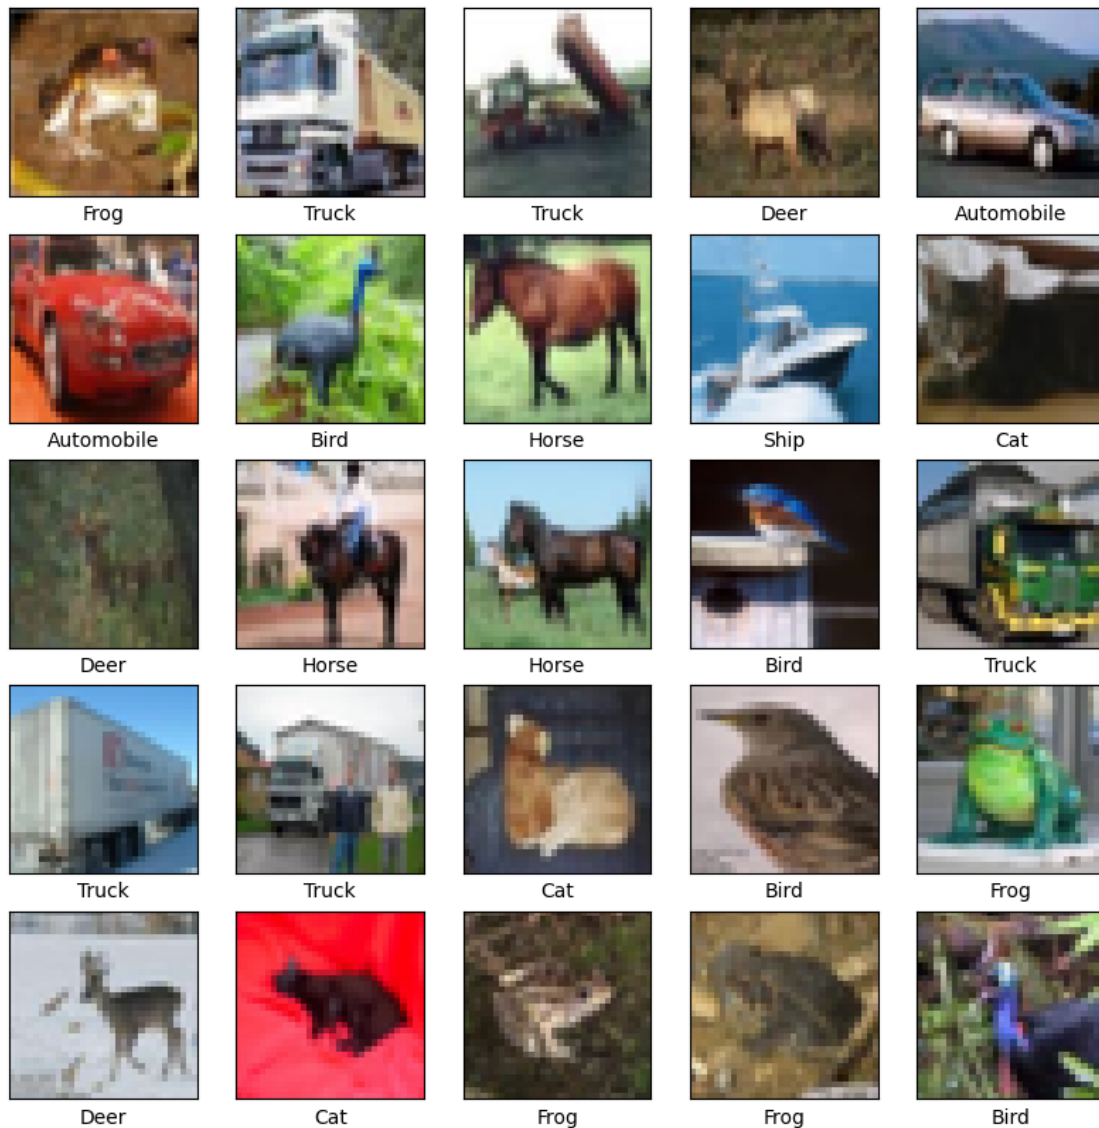
```
[104]: #importar el dataset CIFAR-10
(train_images, train_labels), (test_images, test_labels) = datasets.cifar10.
↳load_data()

#normlizar las imagenes oara simplificar el procesamiento de la red neuronal
↳(cambiar los pixeles a valores entre 0 y 1)
train_images, test_images = train_images/255.0, test_images/255.0
```

1.1 Validacion de los datos

```
[105]: # nombrar las etiquetas de las predicciones para simplificar la interpretacion
↳de los resultados
class_names = ['Airplane', 'Automobile', 'Bird', 'Cat', 'Deer', 'Dog', 'Frog',
↳'Horse', 'Ship', 'Truck' ]
```

```
[106]: plt.figure(figsize=(10,10))
for i in range(25):
    plt.subplot(5,5,i+1)
    plt.xticks([])
    plt.yticks([])
    plt.grid(False)
    plt.imshow(train_images[i])
    plt.xlabel(class_names[train_labels[i][0]])
plt.show()
```



1.2 Capas de convolución

```
[135]: model = models.Sequential()
#parametros de: Conv2D(filtros, kernel size, funcion de activacion, tamaño de input y cuantos canales)

model.add(layers.Conv2D(64,(3,3),activation = 'relu', input_shape=(32,32,3)))
model.add(layers.MaxPooling2D(2,2))
model.add(layers.Conv2D(128,(3,3),activation = 'relu'))
model.add(layers.MaxPooling2D(2,2))
model.add(layers.Conv2D(256,(3,3),activation = 'relu'))
```

1.3 Arquitectura

```
[136]: model.summary()
```

Model: "sequential_14"

Layer (type)	Output Shape	Param #
conv2d_40 (Conv2D)	(None, 30, 30, 64)	1792
max_pooling2d_27 (MaxPooling2D)	(None, 15, 15, 64)	0
conv2d_41 (Conv2D)	(None, 13, 13, 128)	73856
max_pooling2d_28 (MaxPooling2D)	(None, 6, 6, 128)	0
conv2d_42 (Conv2D)	(None, 4, 4, 256)	295168

=====
Total params: 370816 (1.41 MB)
Trainable params: 370816 (1.41 MB)
Non-trainable params: 0 (0.00 Byte)
=====

1.4 Capas densas

```
[137]: # tenemos que hacer la salida de 4x4x256 a una sola dimension
```

```
[138]: model.add(layers.Flatten())  
# 64 neuronas, el numero de neuronas varia la presicion de la red neuronal  
model.add(layers.Dense(64, activation = 'relu'))  
model.add(layers.Dense(10, activation = 'sigmoid')) # 10 canales de salida porque  
→hay 10 clases, acotar los numeros entre 0 y 1
```

```
[139]: # ver la arquitectura de la red para comprobar que este bien construida  
model.summary()  
  
## 64 por 4 por 4 da 1024
```

Model: "sequential_14"

Layer (type)	Output Shape	Param #
conv2d_40 (Conv2D)	(None, 30, 30, 64)	1792
max_pooling2d_27 (MaxPooling2D)	(None, 15, 15, 64)	0

conv2d_41 (Conv2D)	(None, 13, 13, 128)	73856
max_pooling2d_28 (MaxPooling2D)	(None, 6, 6, 128)	0
conv2d_42 (Conv2D)	(None, 4, 4, 256)	295168
flatten_14 (Flatten)	(None, 4096)	0
dense_32 (Dense)	(None, 64)	262208
dense_33 (Dense)	(None, 10)	650

```
=====
Total params: 633674 (2.42 MB)
Trainable params: 633674 (2.42 MB)
Non-trainable params: 0 (0.00 Byte)
-----
```

1.5 Entrenamiento

```
[140]: from matplotlib.rcsetup import validate_font_properties
model.compile(optimizer = 'adam',
              loss = tf.keras.losses.SparseCategoricalCrossentropy(from_logits =
→ True),
              metrics = ['accuracy'])


# numero de epocas podemos jugar para mejorar la presicion
history = model.fit(train_images, train_labels, epochs = 5, validation_data =
→ (test_images, test_labels))
```

```
Epoch 1/5
1563/1563 [=====] - 11s 5ms/step - loss: 1.4604 -
accuracy: 0.4677 - val_loss: 1.2244 - val_accuracy: 0.5738
Epoch 2/5
1563/1563 [=====] - 9s 6ms/step - loss: 1.0322 -
accuracy: 0.6374 - val_loss: 0.9332 - val_accuracy: 0.6739
Epoch 3/5
1563/1563 [=====] - 8s 5ms/step - loss: 0.8544 -
accuracy: 0.7003 - val_loss: 0.8909 - val_accuracy: 0.6906
Epoch 4/5
1563/1563 [=====] - 8s 5ms/step - loss: 0.7314 -
accuracy: 0.7459 - val_loss: 0.8395 - val_accuracy: 0.7116
Epoch 5/5
1563/1563 [=====] - 9s 5ms/step - loss: 0.6367 -
accuracy: 0.7765 - val_loss: 0.8286 - val_accuracy: 0.7257
```

1.6 Evaluacion

```
[141]: plt.plot(history.history['accuracy'],label = 'accuracy')
plt.plot(history.history['val_accuracy'], label = 'val_accuracy')
plt.xlabel('Epoch')
plt.ylabel('Accuracy')
plt.legend()
plt.ylim([0.5,1])
```

[141]: (0.5, 1.0)



```
[142]: test_loss, test_acc = model.evaluate(test_images, test_labels, verbose=2)
```

313/313 - 1s - loss: 0.8286 - accuracy: 0.7257 - 769ms/epoch - 2ms/step

```
[143]: print("Accuracy: ", test_acc)
```


Accuracy: 0.7257000207901001

1.7 Predecir

dentro de model despues del fit ahora estan los pesos y las estructuras

```
[144]: n= 115 #numero de imagen (total de 1000 imagenes)
```

```
plt.figure(figsize= (2,2))
plt.imshow(test_images[n])
plt.xlabel(class_names[test_labels[n][0]])
plt.title('Imagen original')
plt.show()
```



```
[145]: predictions = model.predict(test_images)
print(predictions[n]) #probabilidades de cada una de las neruonas en la ultima
      ↪ capa
```

```
313/313 [=====] - 1s 2ms/step
[0.43494222 0.01087931 0.7099051  0.9741867  0.65115905 0.7156717
 0.1395326  0.5821535  0.00905532 0.02709975]
```

```
[146]: import numpy as np
print("La imagen pertence al grupo {} con una probabilidad de {:.2f} %"
      .format(class_names[np.argmax(predictions[n])], 100 + np.max(predictions[n])))
```

La imagen pertence al grupo Cat con una probabilidad de 100.97 %

2 Fashion_mnist

```
[88]: #importar el dataset CIFAR-10
(train_images, train_labels), (test_images, test_labels) = datasets.
      ↪ fashion_mnist.load_data()

#normlizar las imagenes oara simplificar el procesamiento de la red neuronal
      ↪ (cambiar los pixeles a valores entre 0 y 1)
train_images, test_images = train_images/255.0, test_images/255.0
```

2.1 Validación de los datos

```
[89]: # nombrar las etiquetas de las predicciones para simplificar la interpretacion_
      ↪ de los resultados
class_names = ['T-shirt/top', 'Trouser', 'Pullover', 'Dress', 'Coat', 'Sandal',
      ↪ 'Shirt', 'Sneaker', 'Bag', 'Ankle boot' ]
```

```
[90]: plt.figure(figsize=(10,10))
      for i in range(25):
          plt.subplot(5,5,i+1)
          plt.xticks([])
          plt.yticks([])
          plt.grid(False)
          plt.imshow(train_images[i])
          plt.xlabel(class_names[train_labels[i]])
      plt.show()
```



2.2 Capas de convolución

```
[91]: model = models.Sequential()
#parametros de: Conv2D(filtros, kernel size, funcion de activacion, tamaño de_
↳input y cuantos canales)
# 1 canal porque las imagenes están en grayscale
model.add(layers.Conv2D(64,(3,3),activation = 'relu', input_shape=(28,28,1)))
model.add(layers.MaxPooling2D(2,2))
model.add(layers.Conv2D(128,(3,3),activation = 'relu'))
model.add(layers.MaxPooling2D(2,2))
model.add(layers.Conv2D(128,(3,3),activation = 'relu'))
```


2.3 Arquitectura

```
[92]: model.summary()
```

Model: "sequential_9"

Layer (type)	Output Shape	Param #
conv2d_24 (Conv2D)	(None, 26, 26, 64)	640
max_pooling2d_16 (MaxPooling2D)	(None, 13, 13, 64)	0
conv2d_25 (Conv2D)	(None, 11, 11, 128)	73856
max_pooling2d_17 (MaxPooling2D)	(None, 5, 5, 128)	0
conv2d_26 (Conv2D)	(None, 3, 3, 128)	147584

=====
Total params: 222080 (867.50 KB)
Trainable params: 222080 (867.50 KB)
Non-trainable params: 0 (0.00 Byte)
=====

2.4 Capas densas

```
[93]: # tenemos que hacer la salida de 3x3x128 a una sola dimension
```

```
[94]: model.add(layers.Flatten())  
# 64 neuronas porq hay 128 filtros, el numero de neuronas varia la presicion de la red neuronal  
model.add(layers.Dense(64, activation = 'relu'))  
model.add(layers.Dense(10, activation = 'sigmoid')) # 10 canales de salida porq hay 10 clases, acotar los numeros entre 0 y 1
```

```
[95]: # ver la arquitectura de la red oara comprobar que este bien construida  
model.summary()
```

```
## 128 por 4 por 4 da 2048
```

Model: "sequential_9"

Layer (type)	Output Shape	Param #
conv2d_24 (Conv2D)	(None, 26, 26, 64)	640

max_pooling2d_16 (MaxPooli ng2D)	(None, 13, 13, 64)	0
conv2d_25 (Conv2D)	(None, 11, 11, 128)	73856
max_pooling2d_17 (MaxPooli ng2D)	(None, 5, 5, 128)	0
conv2d_26 (Conv2D)	(None, 3, 3, 128)	147584
flatten_9 (Flatten)	(None, 1152)	0
dense_18 (Dense)	(None, 64)	73792
dense_19 (Dense)	(None, 10)	650

```
=====
Total params: 296522 (1.13 MB)
Trainable params: 296522 (1.13 MB)
Non-trainable params: 0 (0.00 Byte)
-----
```

2.5 Entrenamiento

```
[96]: from matplotlib.rcsetup import validate_font_properties
model.compile(optimizer = 'adam',
              loss = tf.keras.losses.SparseCategoricalCrossentropy(from_logits =
↳ True),
              metrics = ['accuracy'])

# numero de epocas podemos jugar para mejorar la presicion
history = model.fit(train_images, train_labels, epochs = 25, validation_data =
↳ (test_images, test_labels))
```

```
Epoch 1/25
1875/1875 [=====] - 11s 5ms/step - loss: 0.4517 -
accuracy: 0.8351 - val_loss: 0.3534 - val_accuracy: 0.8739
Epoch 2/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.2966 -
accuracy: 0.8916 - val_loss: 0.3222 - val_accuracy: 0.8837
Epoch 3/25
1875/1875 [=====] - 9s 5ms/step - loss: 0.2494 -
accuracy: 0.9078 - val_loss: 0.2600 - val_accuracy: 0.9063
Epoch 4/25
1875/1875 [=====] - 9s 5ms/step - loss: 0.2177 -
accuracy: 0.9197 - val_loss: 0.2708 - val_accuracy: 0.9056
Epoch 5/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.1894 -
```

accuracy: 0.9300 - val_loss: 0.2515 - val_accuracy: 0.9103
Epoch 6/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.1668 -
accuracy: 0.9372 - val_loss: 0.2746 - val_accuracy: 0.9083
Epoch 7/25
1875/1875 [=====] - 9s 5ms/step - loss: 0.1478 -
accuracy: 0.9451 - val_loss: 0.2577 - val_accuracy: 0.9147
Epoch 8/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.1287 -
accuracy: 0.9518 - val_loss: 0.2705 - val_accuracy: 0.9141
Epoch 9/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.1123 -
accuracy: 0.9572 - val_loss: 0.2844 - val_accuracy: 0.9149
Epoch 10/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.1017 -
accuracy: 0.9616 - val_loss: 0.3253 - val_accuracy: 0.9059
Epoch 11/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0890 -
accuracy: 0.9665 - val_loss: 0.3254 - val_accuracy: 0.9146
Epoch 12/25
1875/1875 [=====] - 9s 5ms/step - loss: 0.0833 -
accuracy: 0.9684 - val_loss: 0.3592 - val_accuracy: 0.9158
Epoch 13/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0732 -
accuracy: 0.9726 - val_loss: 0.3460 - val_accuracy: 0.9085
Epoch 14/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0676 -
accuracy: 0.9742 - val_loss: 0.4117 - val_accuracy: 0.9131
Epoch 15/25
1875/1875 [=====] - 9s 5ms/step - loss: 0.0629 -
accuracy: 0.9762 - val_loss: 0.3978 - val_accuracy: 0.9078
Epoch 16/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0614 -
accuracy: 0.9776 - val_loss: 0.4097 - val_accuracy: 0.9150
Epoch 17/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0524 -
accuracy: 0.9800 - val_loss: 0.4951 - val_accuracy: 0.9039
Epoch 18/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0504 -
accuracy: 0.9814 - val_loss: 0.4714 - val_accuracy: 0.9146
Epoch 19/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0480 -
accuracy: 0.9821 - val_loss: 0.4636 - val_accuracy: 0.9131
Epoch 20/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0471 -
accuracy: 0.9826 - val_loss: 0.4922 - val_accuracy: 0.9096
Epoch 21/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0447 -

```

accuracy: 0.9836 - val_loss: 0.5087 - val_accuracy: 0.9139
Epoch 22/25
1875/1875 [=====] - 9s 5ms/step - loss: 0.0385 -
accuracy: 0.9852 - val_loss: 0.5210 - val_accuracy: 0.9104
Epoch 23/25
1875/1875 [=====] - 8s 5ms/step - loss: 0.0382 -
accuracy: 0.9863 - val_loss: 0.5558 - val_accuracy: 0.9086
Epoch 24/25
1875/1875 [=====] - 8s 4ms/step - loss: 0.0419 -
accuracy: 0.9852 - val_loss: 0.5701 - val_accuracy: 0.9109
Epoch 25/25
1875/1875 [=====] - 9s 5ms/step - loss: 0.0404 -
accuracy: 0.9856 - val_loss: 0.5659 - val_accuracy: 0.9100

```


2.6 Evaluación

```

[97]: plt.plot(history.history['accuracy'],label = 'accuracy')
plt.plot(history.history['val_accuracy'], label = 'val_accuracy')
plt.xlabel('Epoch')
plt.ylabel('Accuracy')
plt.legend()
plt.ylim([0.5,1])

```

[97]: (0.5, 1.0)



```
[98]: test_loss, test_acc = model.evaluate(test_images, test_labels, verbose=2)
```

313/313 - 1s - loss: 0.5659 - accuracy: 0.9100 - 718ms/epoch - 2ms/step

```
[99]: print("Accuracy: ", test_acc)
```


Accuracy: 0.9100000262260437

2.7 Predecir

dentro de model despues del fit ahora estan los pesos y las estructuras

```
[100]: n= 115 #numero de imagen (total de 60000 imagenes)
```

```
plt.figure(figsize= (2,2))
plt.imshow(test_images[n])
plt.xlabel(class_names[test_labels[n]])
plt.title('Imagen original')
plt.show()
```



```
[101]: predictions = model.predict(test_images)
print(predictions[n]) #probabilidades de cada una de las neruonas en la ultima_
      ↪ capa
```

313/313 [=====] - 1s 2ms/step
[5.4112636e-04 4.6971396e-14 1.0000000e+00 6.4067180e-12 2.0459828e-01
1.3794807e-03 6.1761029e-03 8.0866054e-13 7.7909426e-14 9.6753413e-12]

```
[102]: import numpy as np
print("La imagen pertenece al grupo {} con una probabilidad de {:.2f} %"
```

```
.format(class_names[np.argmax(predictions[n])], 100 + np.max(predictions[n])))
```

La imagen pertenece al grupo Pullover con una probabilidad de 101.00 %

3 Conclusión

Para el ejercicio de Cifar10, se sabe que son imágenes en RGB por ende desde un principio se sabe que el input es de 3 canales; también se hacen 3 capas de convolución comenzando con 64 hasta alcanzar las 256 neuronas; y al momento de hacer las capas densas, y observando la arquitectura del modelo de estar la capa (4x4x256) se hace un Flatten para que se convierta a 1 dimensión con output de (None,10). Continuando con el entrenamiento, se realizaron varias pruebas, ya que a pesar de que el número de neuronas influye en el accuracy, también lo hace el número de épocas, por ende, para evitar un overfitting se realizaron 5 épocas en el cual, se logra alcanzar el accuracy por encima del 70%, el cual en mi ejercicio fue del 72%; teniendo así una predicción donde la imagen dada como input fue un Cat y la predicción fue un Cat.

Hablando sobre Fashion_mnist, se toma en cuenta que las imágenes de este dataset, no vienen en un formato de RGB sino en grayscale, por ende, en vez de 3 canales como en Cifar10, aquí es 1 canal, ya que solo se obtiene 0 ó 1 como valores de entrada, este “1” fue declarado en el input de la convolución, donde se observa que su arquitectura llega a (3x3x128) y gracias a las capas densas llega a (None, 10). Dentro del entrenamiento se realizan 25 épocas ya que jugando un poco con este número se obtiene el mejor accuracy con un 91%, el cual al momento de hacer la predicción se pone como input una imagen “Pullover”, y la predicción es correcta obteniendo “Pullover”